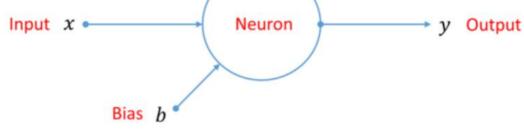
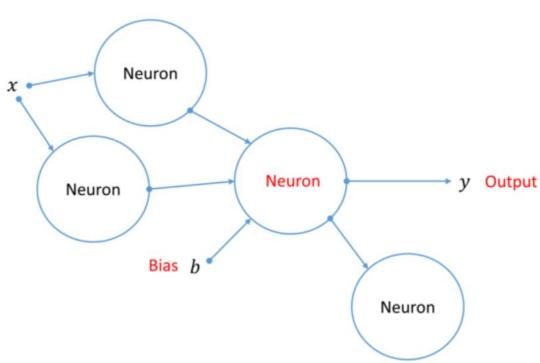
# 인공신경망 퍼셉트론의 이해

## 인공 신경 세포(Artificial Neuron)

- 뉴런
  - \_ 입력
  - 편향(bias)

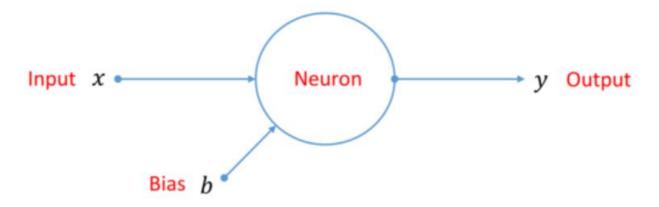


- 신경망(network)
  - 뉴런의 연결



# 입력과 출력

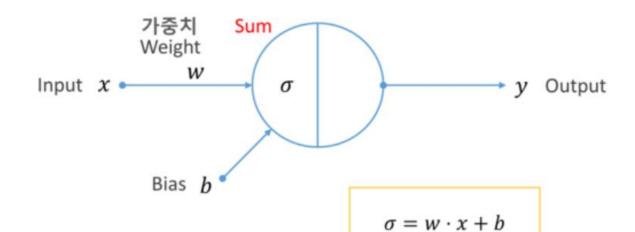
- 편향(bias)
  - 편향을 조정해 출력을 맞춤



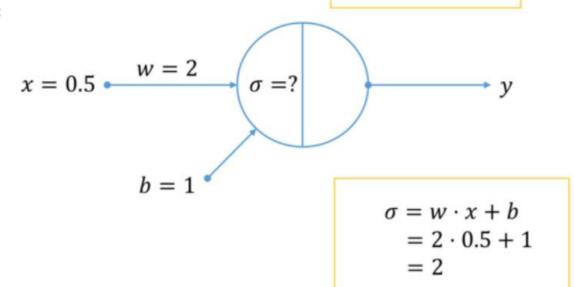
Input x	Output y	
Size of house	Price	
Time spent for studying	Score in exam	

## 뉴런 연산

• 뉴런 식

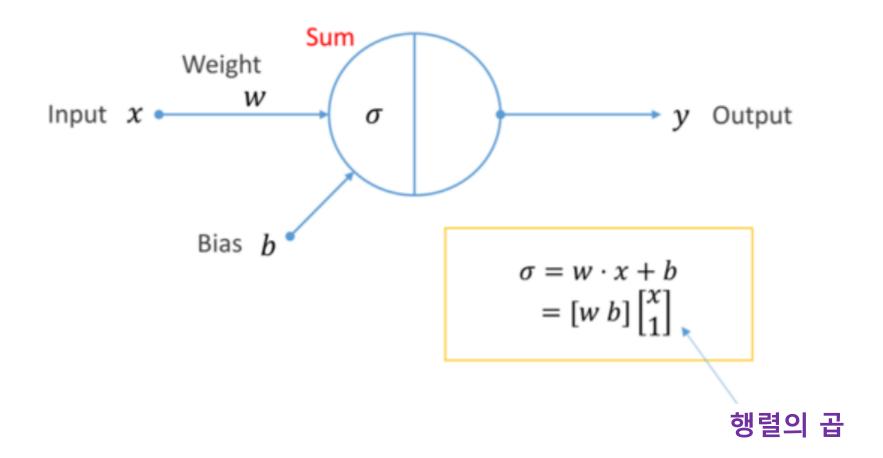


• 가중치와 편향



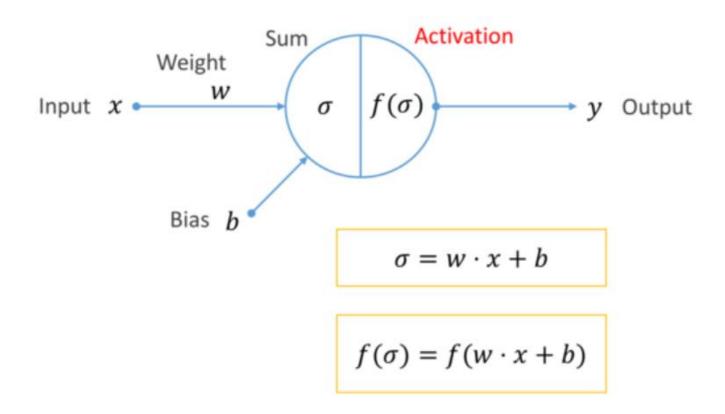
Python

### 행렬 곱 연산



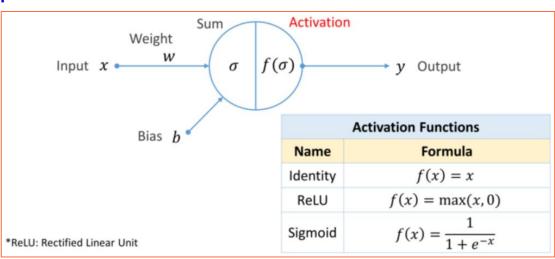
### 활성화

- 활성화 함수
  - 뉴런의 출력 값을 정하는 함수

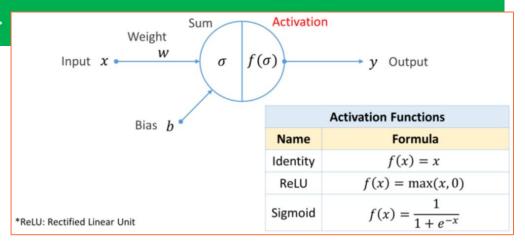


### 활성화 함수 ReLU, sigmoid

- ReLU(교재 p43)
  - Rectified(정류된) Linear Unit(선형 함수, y=x를 의미)
    - 선형 함수를 정류하여 0 이하는 모두 0으로 한 함수
    - max(x, 0)
      - 양수만 사용
  - 2010년 이후
    - 층이 깊어질수록(deep) 많이 활용
      - 양수를 그대로 반환하므로 값의 왜곡이 적어지는 효과
    - 토론토 대학 힌트 교수
- Sigmoid
  - s자 형태의곡선이라는 의미
    - 예전에 많이 사용



#### 다양한 활성화 함수 종류



#### **Activation Functions**

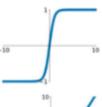
#### Sigmoid

$$\sigma(x) = \frac{1}{1 + e^{-x}}$$



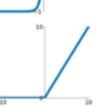
#### tanh

tanh(x)



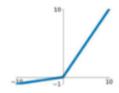
#### ReLU

 $\max(0,x)$ 



#### Leaky ReLU

 $\max(0.1x, x)$ 

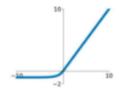


#### Maxout

 $\max(w_1^T x + b_1, w_2^T x + b_2)$ 

#### **ELU**

$$\begin{cases} x & x \ge 0\\ \alpha(e^x - 1) & x < 0 \end{cases}$$

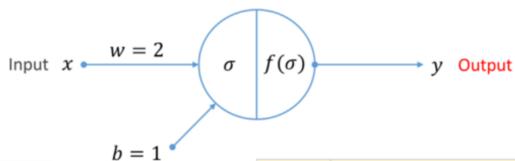


Different Activation Functions and their Graphs

#### 입출력의 예

- 출력 함수로
  - 동일(identity) 함수(또는 리니어 함수)를 적용

$$y = f(\sigma) = f(w \cdot x + b) = w \cdot x + b$$
  
with **identity** (or **linear**) activation functions

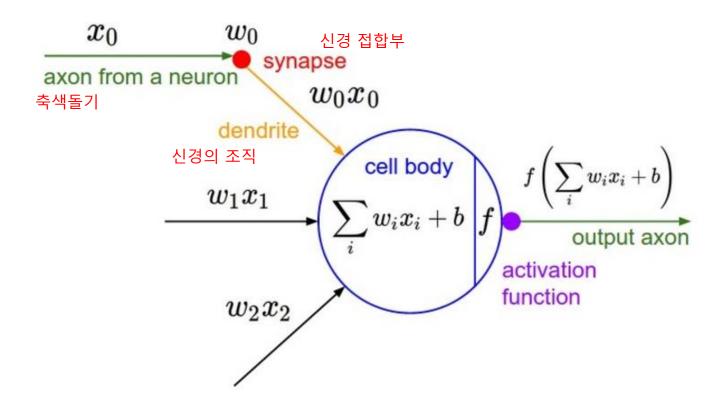


	1 /
1	1
<u></u>	1

f(x)	=	x
, (1)	_	$\lambda$

Input x	Output y
0	$y = f(2 \cdot 0 + 1) = 1$
1	$y = f(2 \cdot 1 + 1) = 3$
2	$y = f(2 \cdot 2 + 1) = 5$

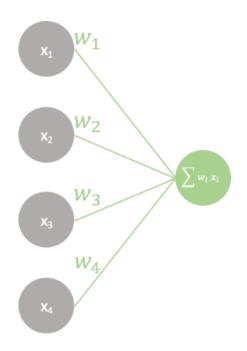
#### 일반화된 인공신경망



#### 활성화 함수와 편향

- 결과 값이 임계 값 역할
  - 결과가 임계 값 이상이면 활성화
  - 결과가 임계 값 미만이면 비활성화

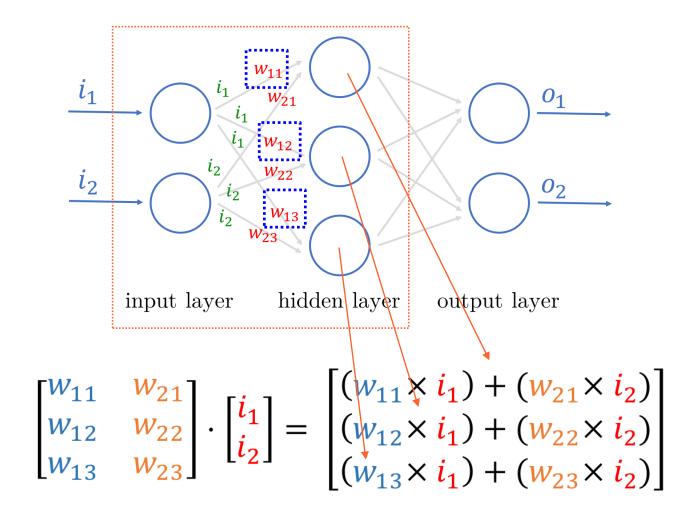
Input layer Output layer



#### Perceptron Unit

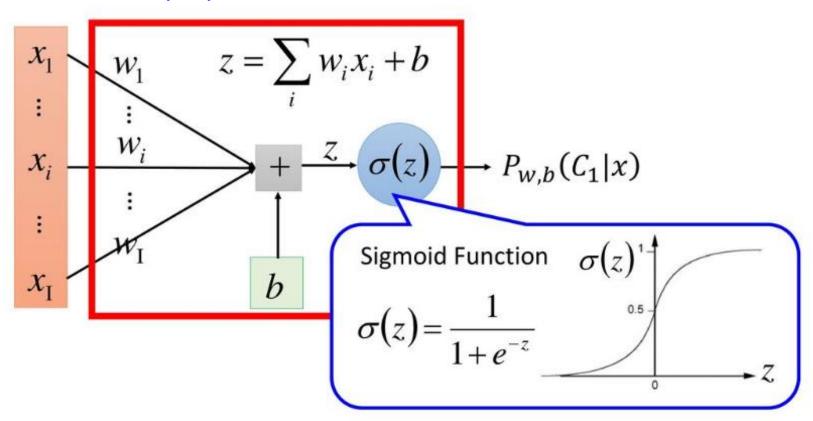
$$f_{w}(x) = \begin{cases} \sum w_{i}x_{i} \ge \theta \to \text{neuron fires} \\ \sum w_{i}x_{i} < \theta \to \text{neuron doesn't fire} \end{cases}$$

#### 입력 2개, 출력 3개인 신경망 연산



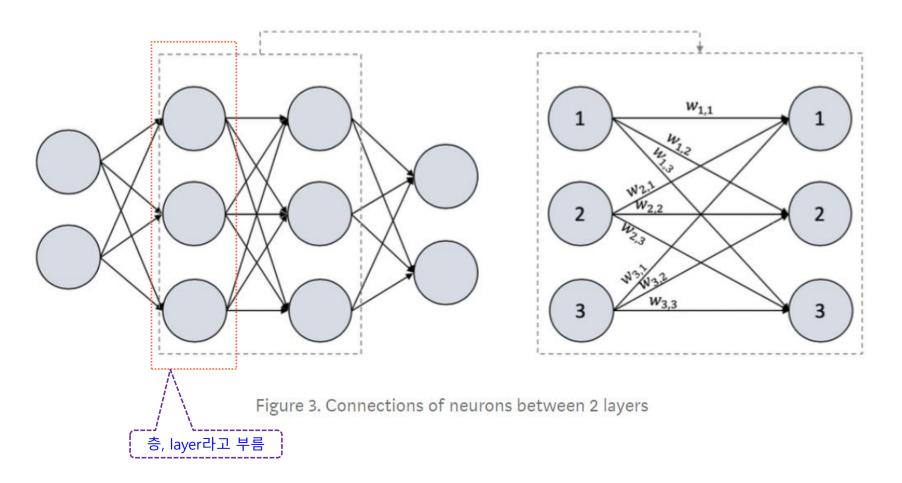
#### 인공신경망의 시그모이드 함수

- 활성화 함수의 예
  - 시그모이드 함수
    - 출력 값이 (0~1)



### 가중치

• 3 × 3의 가중치 실수





# 인공 신경망 행렬 연산

# 입력의 특징 $(x_1 x_2 x_3 ... x_i)$ 과 입력의 자료 수

- 특징 n개가 있는 뉴런 신경망에서 하나의 출력 계산
  - ✓ 샘플 수 1개에 대한 계산

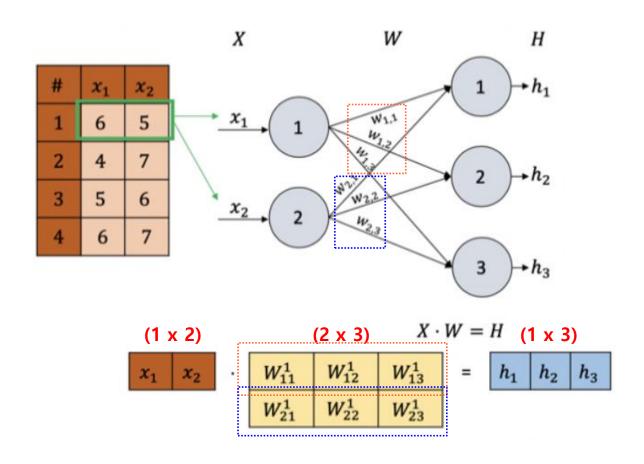
✓ 샘플 수 s개에 대한 계산






#### 신경망 행렬 계산

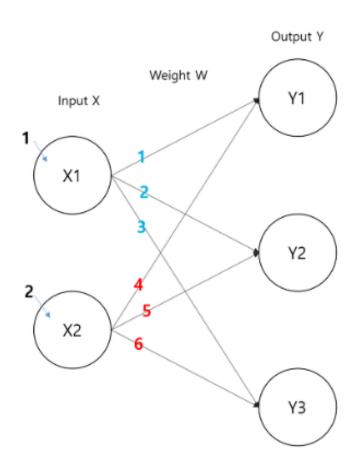
- 특징 2개
  - 샘플 수 4



## 뉴런 계산



# 계산 사례





$$\begin{pmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \end{pmatrix}$$
 (9 12 15)

© sacko

#### 하나의 출력 뉴런 연산

Input layer

• 활성화 함수로 시그모이드 함수 적용

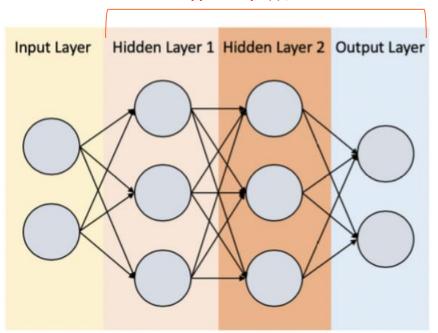
Output layer

 $z(x) = w_1 x_1 + w_2 x_2 + w_3 x_3 + w_4 x_4 + b$   $g(z) = \frac{1}{1 + e^{-z}}$ 

## 층과 가중치

#### • 뉴런 층과 가중치 층

#### 뉴런이 있는 층



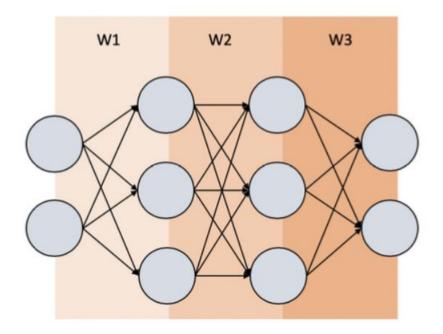
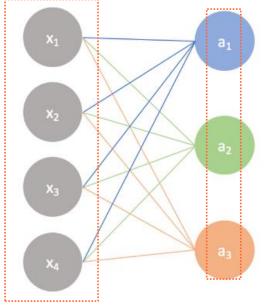


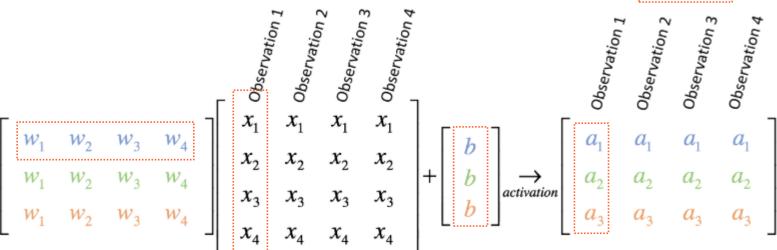
Figure 7. Layers of neuron vs Layers of weights

#### 행령의 다른 표현

- 입력을 오른쪽 행렬에 배치
- 가중치는 왼쪽 행렬에 배치
- 곱의 순서도 변환

#### Using multiple observations





# 활성화 함수 그리기

# 실습 파일

- 파일 생성
  - 06-neuron-activation-dense.ipynb

#### 자연수와 자연수의 지수 승

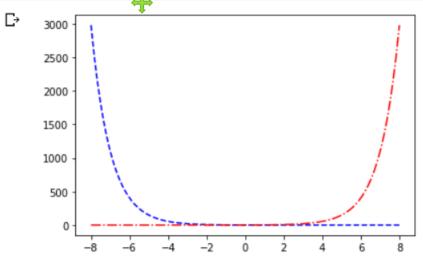
- e
  - 자연수, 오일러 수
  - 2.71828
- $y = e^{-x}$
- $y = e^x$

```
[76] import numpy as np
np.e
```

2.718281828459045

```
[77] import numpy as np
import matplotlib.pylab as plt

plt.figure(figsize=(6, 4))
x = np.linspace(-8, 8, 100)
plt.plot(x, np.exp(-x), 'b---')
_ = plt.plot(x, np.exp(x), 'r-.')
```



#### 시그모이드 함수

- S자 곡선
  - (0, 1) 사이의 값

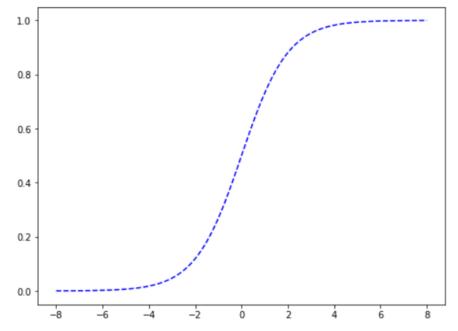
$$h(x) = \frac{1}{1 + e^{-x}}$$

[5] np.e

C→ 2.718281828459045

```
[44] 1 import numpy as np
2 import matplotlib.pylab as plt
3
4 def sigm_func(x): # sigmoid 함수
5 return 1 / (1 + np.exp(-x))
6
7 # 시그모이드 함수 그리기
8 plt.figure(figsize=(8, 6))
9 x = np.linspace(-8, 8, 100)
10 plt.plot(x, sigm_func(x), 'b--')
```

[<matplotlib.lines.Line2D at 0x7f93b4130cc0>]



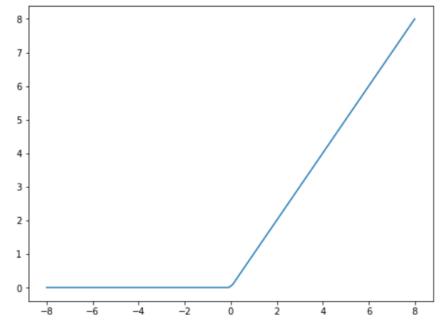
#### ReLU 함수

- X
  - 0, 음수면 0
  - 양수면 x

$$h(x) = \begin{cases} 0 & (x \le 0) \\ x(x > 0) \end{cases}$$

```
[45] 1 import numpy as np
2 import matplotlib.pylab as plt
3
4 def relu_func(x): # ReLU(Rectified Linear Unit, 정류된 선형 유닛) 함수
5 return np.maximum(0, x)
6 #return (x>0)*x # same
7
8 # ReLU 함수 그리기
9 plt.figure(figsize=(8, 6))
10 x = np.linspace(-8, 8, 100)
11 plt.plot(x, relu_func(x))
```

#### [<matplotlib.lines.Line2D at 0x7f93b409b748>]



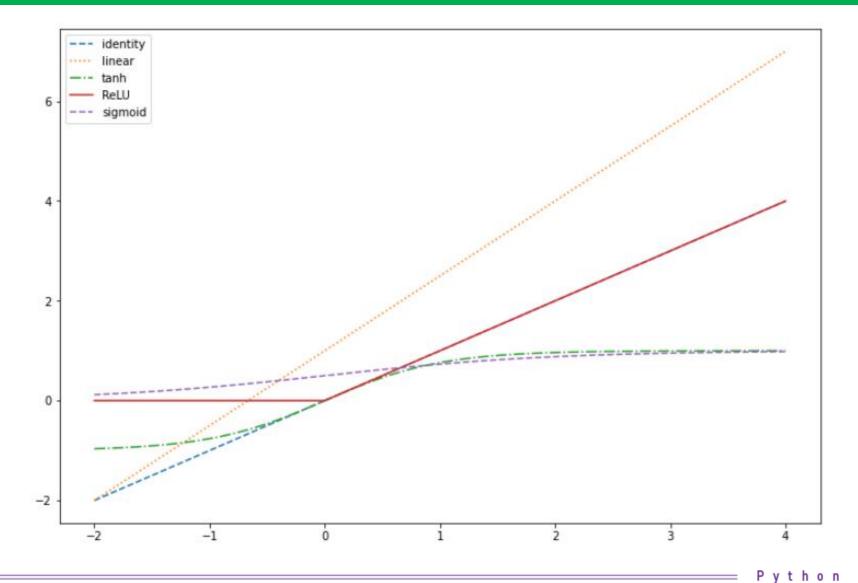
#### 시그모이드 ReLU 함께 그리기

```
ReLU
                                            sigmoid
                                    3.5
                                    3.0
                                    2.5
import numpy as np
import matplotlib.pylab as plt
                                    2.0
# ReLU(Rectified Linear Unit
# (정류된 선형 유닛) 함수
                                   1.5
def relu func(x):
    return np.maximum(0, x)
                                    1.0
    \#return (x>0)*x \# same
def sigm func(x): # sigmoid 함수
                                    0.5
    return 1 / (1 + np.exp(-x))
                                    0.0
# 그래프 그리기
plt.figure(figsize=(8, 6))
x = np.linspace(-4, 4, 100)
y = np.linspace(-0.2, 2, 100)
plt.plot(x, relu func(x), linestyle=':', label="ReLU")
plt.plot(x, sigm func(x), linestyle='--', label="sigmoid")
plt.legend(loc='upper left')
```

#### 다양한 활성화 함수

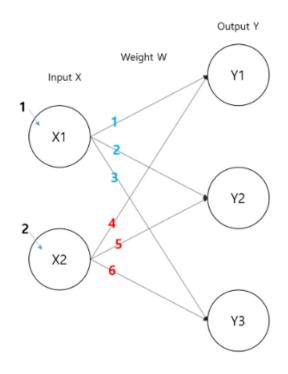
```
import numpy as np
import matplotlib.pylab as plt
def identity func(x): # 항등함수
    return x
def linear func(x): # 1차함수
    return 1.5 * x + 1 # a기울기(1.5), Y절편b(1) 조정가능
def tanh func(x): # TanH 함수
    return np.tanh(x)
def relu func(x): # ReLU(Rectified Linear Unit, 정류된 선형 유닛) 함수
    return np.maximum(0, x)
    \#return (x>0)*x \# same
def sigm func(x): # sigmoid 함수
    return 1 / (1 + np.exp(-x))
# 그래프 그리기
plt.figure(figsize=(12, 8))
x = np.linspace(-2, 4, 100)
plt.plot(x, identity func(x), linestyle='--', label="identity")
plt.plot(x, linear func(x), linestyle=':', label="linear")
plt.plot(x, tanh func(x), linestyle='-.', label="tanh")
plt.plot(x, relu func(x), linestyle='-', label="ReLU")
plt.plot(x, sigm func(x), linestyle='--', label="sigmoid")
plt.legend(loc='upper left')
```

## 활성화 함수 결과



# 인공 신경망 행렬 연산 코드

#### 계산 사례



$$X * W = Y$$
  
1 x 2 \* 2 x 3 = 1 x 3

$$\begin{pmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \end{pmatrix}$$
 (9 12 15)

#### ▼ 뉴런의 행렬 연산

```
[14] x = [[1, 2]]

w = [[1, 2, 3], [4, 5, 6]]

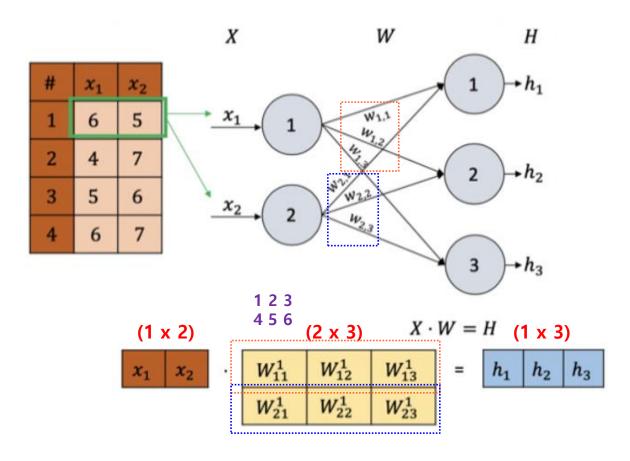
y = tf.matmul(x, w)

y.numpy()
```

□ array([[ 9, 12, 15]], dtype=int32)

#### 신경망 행렬 계산

- 특징 2개
  - 샘플 수 4



#### 특징 2, 샘플 수 4개의 행렬 연산

```
[15] \times = [[6, 5]]
     w = [[1, 2, 3], [4, 5, 6]]
     y = tf.matmul(x, w)
     y.numpy()
r→ array([[26, 37, 48]], dtype=int32)
[16] \times = [[6, 5], [4, 7], [5, 6], [6, 7]]
     w = [[1, 2, 3], [4, 5, 6]]
     y = tf.matmul(x, w)
     y.numpy()
 r→ array([[26, 37, 48],
             [32, 43, 54],
             [29, 40, 51],
             [34, 47, 60]], dtype=int32)
```

#### 행렬의 순서를 바꾼 계산

#### 가중치와 입력 값의 순서도 수정

```
[78] #x = [[6, 5], [4, 7], [5, 6], [6, 7]]

#w = [[1, 2, 3], [4, 5, 6]]

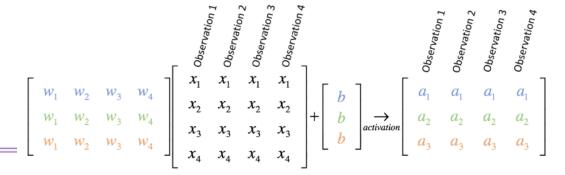
w = [[1, 4], [2, 5], [3, 6]]

x = [[6, 4, 5, 6], [5, 7, 6, 7]]

y = tf.matmul(w, x)

y.numpy()
```

#### Using multiple observations



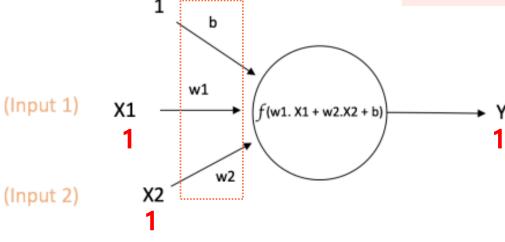
# 논리 게이트 AND OB XOB 신경망 구현

#### AND 게이트 구현

- 뉴런 구조
  - 입력 2개, 편향, 출력 1
  - 구할 값
    - 가중치 2개와 편향 1개

x1	x2	у
0	0	0
0	1	0
1	0	0
1	1	1

(Output)



Output of neuron = Y = f(w1. X1 + w2. X2 + b)

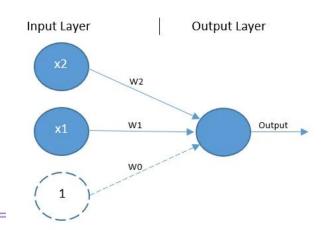


Figure 2: Single Layer Perceptron Network

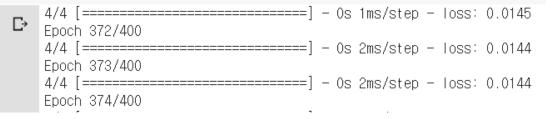
```
# tf.keras 를 이용한 AND 네트워크 계산 import numpy as np x = np.array([[1,1], [1,0], [0,1], [0,0]]) y = np.array([[1], [0], [0], [0]]) model = tf.keras.Sequential([ tf.keras.layers.Dense(units=1, activation='sigmoid', input_shape=(2,)), ]) model.compile(optimizer=tf.keras.optimizers.SGD(Ir=0.3), loss='mse') model.summary()
```

r→ Model: "sequential\_4"

Layer (type) 💠	Output Shape	Param #
dense_6 (Dense)	(None, 1)	3
		=======================================

Total params: 3 Trainable params: 3 Non-trainable params: 0





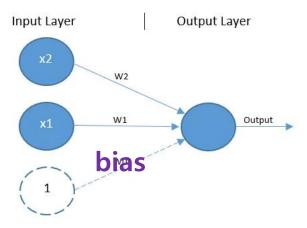
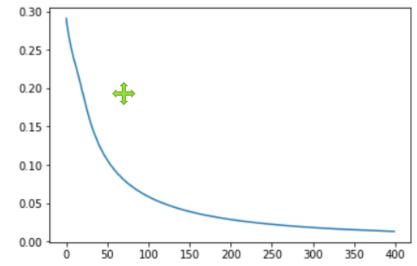


Figure 2: Single Layer Perceptron Network

#### 손실 값 그래프와 결과 예측

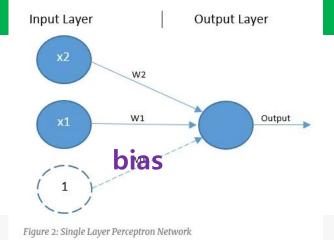
```
[54] # 3.34 2-레이어 XOR 네트워크의 loss 변화를 선 그래프로 표시 import matplotlib.pyplot as plt plt.plot(history.history['loss'])
```

[<matplotlib.lines.Line2D at 0x7efe712955f8>]



```
[59] model.predict(x)
```

#### 가중치와 편향 값 알아 보기



```
[60] for weight in model.weights:
print(weight)
```


- [61] model.weights[0]
- [62] model.weights[1]
- <tf. Variable 'dense\_6/bias:0' shape=(1,) dtype=float32, numpy=array([-5.6813374], dtype=float32)>

# OR 게이트 구현


• 여러분이 직접 해 보세요.

# XOR 문제


- 하나의 퍼셉트론으로는 XOR 게이트는 불가능
  - 마빈 민스키와 시모어 페퍼트가 증명
  - 첫 AI 겨울의 계기



<i>x</i> <sub>1</sub>	$x_2$	у
0	0	0
0	1	1
1	0	1
1	1	1



$x_1$	$x_2$	у
0	0	0
0	1	0
1	0	0
1	1	1



$x_1$	$x_2$	у
0	0	0
0	1	1
1	0	1
1	1	0

# XOR 해결

- 뉴런 3 개의 2층으로 가능
  - 모델이 구해야 할 총 매개변수(가중치와 편향)
    - · 3 \* 2 + 3 \* 1 = 9개

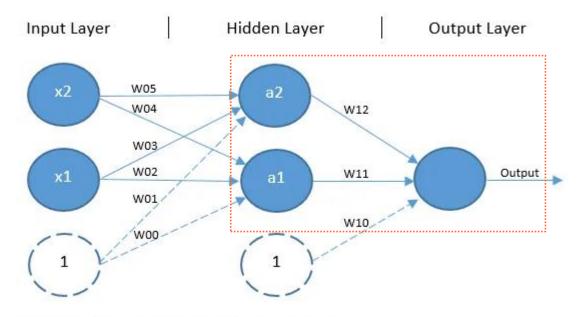


Figure 4: Multilayer Pereceptron Architecture for XOr

#### Sequential 모델

#### • Dense 층

- 가장 기본적인 층
- 인자 units, activation
  - 뉴런 수와 활성화 함수
- 인자 input\_shape
  - 첫 번째 층에서만 정의
  - 입력의 차원을 명시
    - (2, )
    - \_ 2개의 입력을 받는 1차원




Figure 4: Multilayer Pereceptron Architecture for XOr

Output Shape

(None, 2)

(None, 1)

# Sequential 모델과 딥러닝 구조

- 입력, 은닉, 출력 층
  - 패러미터 수
  - (입력측 뉴런 수 + 1) \* (출력측 뉴런 수) x = np.array([[1,1], [1,0], [0,1], [0,0]])

```
x = np.array([[1,1], [1,0], [0,k], [0,0]])

y = np.array([[0], [1], [1], [0]])
```

model = tf.keras.Sequential([

tf.keras.layers.Dense(units=2; activation='sigmoid', input shape=(2,))

tf.keras.layers.Dense(units=1; activation='sigmoid')

Hidden Layer **Output Layer** Input Layer W05 x2 a2 W04 W12 W03 W02 W11 Output **x1** W01 W10 W00

Model: "sequential 1"

dense\_2 (Dense)

dense\_3 (Dense)

Total params: 9

Trainable params: 9

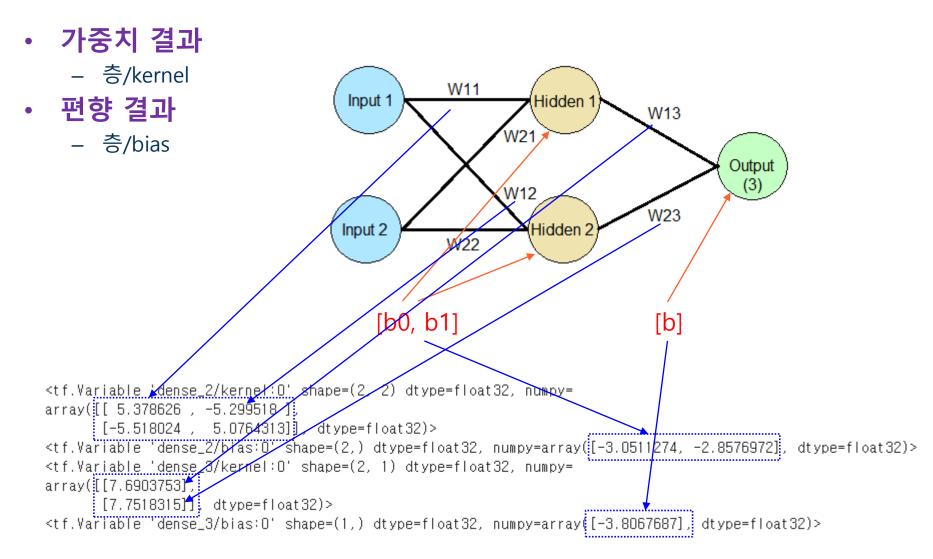
Non-trainable params: 0

Figure 4: Multilayer Pereceptron Architecture for XOr

#### XOR 게이트 구현 소스

```
# 3.27 tf.keras 를 이용한 XOR 네트워크 계산
import tensorflow as tf
import numpy as np
x = np.array([[1,1], [1,0], [0,1], [0,0]])
y = np.array([[0], [1], [1], [0]])
model = tf.keras.Sequential([
    tf.keras.layers.Dense(units=2, activation='sigmoid', input shape=(2,)),
    tf.keras.layers.Dense(units=1, activation='sigmoid')
1)
model.compile(optimizer=tf.keras.optimizers.SGD(lr=0.3), loss='mse')
model.summary()
# 3.28 tf.keras 를 이용한 XOR 네트워크 학습
history = model.fit(x, y, epochs=2000, batch size=1)
# 3.29 tf.keras 를 이용한 XOR 네트워크 평가
print(model.predict(x))
# 3.30 XOR 네트워크의 가중치와 편향 확인
for weight in model.weights: Epoch 1999/2000
    print(weight)
                                Epoch 2000/2000
                                4/4 [================== ] - Os 1ms/step - loss: 0.0017
                               [[0.04060324]
                               [0.9609237]
                                [0.96031225]
                                [0.04571233]]
                                <tf.Variable 'dense_2/kernel:0' shape=(2, 2) dtype=float32, numpy=
                                array([[ 5.378626 , -5.299518 ],
                                     [-5.518024 , 5.0764313]], dtype=float32)>
                                <tf.Variable 'dense_2/blas:0' shape=(2,) dtype=float32, numpy=array([-3.0511274, -2.8576972], dtype=float32)>
                                <tf. Variable 'dense_3/kernel:0' shape=(2, 1) dtype=float32, numpy=
                                array([[7.6903753],
                                     [7.7518315]], dtype=float32)>
                                <tf.Variable 'dense_3/bias:0' shape=(1,) dtype=float32, numpy=array([-3.8067687], dtype=float32)>
```

# 가중치와 model.weights



#### XOR 모델의 학습 과정 시각화

- 손실(loss) 또는 오류 값의 변화
  - 가로는 에폭의 수
    - 학습 횟수가 증가하면서 계속 손실은 작아짐

```
# 3.34 2-레이어 XOR 네트워크의 loss 변화를 선 그래프로 표시 import matplotlib.pyplot as plt
```

plt.plot(history.history['loss'])

